

A incerteza quando o mundo muda

September 23, 2026

Sumário

Como este livro mede	5
1 A medida, o corte e o preço	7
1.1 Quanto eu posso perder amanhã	7
1.2 O dado e a regra	7
1.3 A conta que o corte faz sozinho	8
1.4 Os blocos têm data	9
1.5 O preço muda de lugar	9
1.6 Uma linha erguida no passado	10
2 O orçamento do alarme	13
2.1 O vigia	13
2.2 Quanto ele soa quando nada muda	13
2.3 Quanto ele demora quando algo muda	14
2.4 A troca	14
2.5 O piso	15
2.6 O mesmo corte, lido mais fundo	16
2.7 A forma decide o preço	17
2.8 O que a memória faz	18
2.9 O que fica	19

Como este livro mede

Este livro não afirma nada sem mostrar como se mede. Cada número que aparece no texto sai de um caderno de experimento: um caderno por medição, executável sozinho, com os parâmetros no topo para quem quiser mexer. O caderno termina gravando o resultado num arquivo, e cada figura sai duas vezes — em papel, para este livro, e em imagem, para inspeção.

O texto então não escreve o número: ele cita o comando que o laboratório gerou. Isso parece detalhe e não é: um número digitado à mão pode divergir da medição sem que ninguém perceba, e um número citado não pode, porque não existe em dois lugares.

A medição de abertura serve de exemplo. Ela lê uma série longa de preços e mede a volatilidade em duas escalas de tempo: 0,1925 ao longo de todo o histórico e 0,1299 no último ano, uma razão de 0,6749 em 6718 dias úteis. A figura mostra as duas curvas que produzem esses números.




Figure 1: Preço e volatilidade da mesma série, em duas escalas de tempo. A linha tracejada é a volatilidade do histórico inteiro; a curva azul é a janela móvel de um ano.

Capítulo 1

A medida, o corte e o preço

1.1 Quanto eu posso perder amanhã

O mercado fechou, e a pergunta volta quase toda noite com as mesmas palavras: quanto eu posso perder amanhã? Quem carrega dinheiro aplicado não pergunta por gosto de adivinhar. A resposta decide se a posição cabe no bolso de quem a carrega, e a posição que não cabe é desmontada — muitas vezes antes de o mercado explicar o que estava acontecendo.

Responder exige duas decisões. A primeira é quantos dias olhar para trás. A segunda é onde pôr a linha dentro desses dias: no pior de todos, no segundo pior, no décimo terceiro. Uma regra escrita por inteiro soa assim: *o corte de hoje é o décimo terceiro pior dia dos últimos 252 pregões*. Ela também traz o que pretende valer: *não passo daqui, dezenove dias em vinte*, isto é, 5% de violação.

Vale fixar quatro palavras, porque nenhuma delas muda de sentido daqui em diante: a **janela** é o pedaço do passado que a regra olha; o **corte** é onde a linha é posta dentro da janela; a **promessa** é a taxa de violação que se anuncia; e a **entrega** é a taxa que de fato acontece.

A linha posta no quantil dos piores dias é a medida de risco mais usada em finanças, discutida e corrigida há décadas [88]. O que se pergunta aqui é menos do que isso, e vem antes: a entrega tem alguma coisa a ver com a promessa?

1.2 O dado e a regra

O dado é o retorno de um dia para o outro. Com o preço de hoje p_t e o de amanhã p_{t+1} ,

$$r_{t+1} = \log \frac{p_{t+1}}{p_t}.$$

O logaritmo não está ali por elegância. Ele faz um preço que desce e volta ao lugar terminar com retornos que somam zero, e é isso que permite acompanhar o dia a dia sem perder o fio da conta:

$$100 \rightarrow 95 : -0,0513; \quad 95 \rightarrow 100 : +0,0513; \quad \text{queda de 5\% pede alta de 5,26\%}.$$

Em porcentagem a volta também acontece, mas com outros números, porque porcentagem multiplica onde o logaritmo soma.

A série é o índice S&P 500, com 6718 pregões, de 4 de janeiro de 2000 a 21 de setembro de 2026. Ela vem do arquivo do projeto anterior, e o empréstimo fica declarado: o dado atravessa, todo número tirado dele é medido de novo neste capítulo.

Sobre essa série a regra toma duas decisões, e só duas. A **janela**: os 252 pregões anteriores a hoje. O **corte**: o décimo terceiro pior deles. O corte de cada dia é erguido com os dias que já passaram e com nenhum outro, de modo que a linha que aparece no gráfico estava lá antes de o dia acontecer. Um corte que espiasse o futuro acertaria sempre, e por isso não valeria nada.

1.3 A conta que o corte faz sozinho

Nos 6466 dias em que havia janela suficiente, a linha foi rompida 332 vezes. Isso dá 5,135% de entrega, contra os 5% anunciados. A diferença é de um décimo de ponto percentual, e a impressão que ela deixa é que a regra funcionou.

Aqui a impressão engana. Quem decidiu o número foi a aritmética de erguer a linha, e não o que o mercado fez.

Proposição 1.1 (a conta do corte). *Suponha que os n dias da janela e o dia seguinte sejam $n + 1$ valores de uma mesma lei contínua, em qualquer ordem igualmente provável. Se o corte é o k -ésimo menor dos n dias da janela, então a probabilidade de o dia seguinte ficar abaixo do corte é $\frac{k}{n + 1}$.*

Prova. Junte os $n + 1$ valores e ponha-os em ordem crescente. Todas as ordens são igualmente prováveis, então a posição do dia seguinte nessa fila é uniforme entre as $n + 1$ posições. O dia seguinte fica abaixo do corte exatamente quando ocupa uma das k primeiras posições, que são as ocupadas pelos k menores da janela. Logo a probabilidade é $k/(n + 1)$. $\square$

A lei ser contínua serve para que dias empatados tenham probabilidade zero; e a hipótese de que todas as ordens são igualmente prováveis é a hipótese de que os dias não têm nada a dizer uns sobre os outros, que é justamente o que um mundo que muda viola. A proposição não prevê o que vai acontecer. Ela é o contraste contra o qual o que aconteceu se lê.

Ela também é um caso pequeno e exato de um viés conhecido: o quantil estimado de uma amostra não entrega a probabilidade que se anuncia, e o tamanho do erro depende do tamanho da amostra [13].

Com $n = 252$ e $k = 13$, a conta dá $13/(252 + 1)$, que é 5,138%. Esse número não veio do mercado. Veio da decisão de olhar 252 dias e cortar no décimo terceiro. Se o posto fosse o décimo segundo, a conta daria 4,743%; e a promessa anunciada não está em nenhum dos dois, porque o posto teria de cair entre dois dias, e não existe o décimo terceiro dia e meio de um ano.

O mercado entregou 5,135%: 332 rompimentos em 6466 dias, com poucos milésimos de diferença da conta do corte. Para saber se essa diferença diz alguma coisa, falta o único contraste que responde. É preciso submeter um mundo em que nada muda exatamente à mesma rotina.

Sorteamos 200 séries do tamanho da nossa, com retornos independentes e sempre a mesma lei, e aplicamos a cada uma a mesma regra. A entrega média desses mundos foi $5,139 \pm 0,1091\%$, contra os 5,138% da conta; o mundo real entregou 5,135%. Os três números estão no mesmo lugar.

A média de violações é uma propriedade do corte, e não do mundo. O corte assinou o número antes de qualquer dado chegar, e quem lê só a média lê a própria escolha acreditando estar lendo o mercado.

1.4 Os blocos têm data

A diferença entre os mundos aparece na *forma* com que as violações chegam: espalhadas pelo calendário, ou concentradas em pedaços. Para medir a forma, contamos quantas violações caem em cada janela móvel de 60 dias — a isso chamamos um **bloco** — e olhamos o bloco mais cheio. A promessa de 5% admite 3 violações em 60 dias.

A mediana dos blocos é 2: na maior parte do tempo a linha aguenta mais do que prometeu. O pior bloco tem 20 violações, e termina em 20 de novembro de 2008. Onde a promessa admitia 3, aconteceram 20.

Nos 200 mundos que nunca mudam, o pior bloco de cada um teve, em média, 9,26 violações, e o pior bloco de todos eles chegou a 13. Nenhum passou disso. A série real, com o mesmo tamanho e a mesma rotina, chegou a 20.




Figure 1.1: Violações nos 60 dias anteriores, dia a dia. A linha tracejada é o que a promessa de 5% admite; a pontilhada é o pior bloco que apareceu em 200 mundos que nunca mudam.

A figura mostra o que a média esconde. A série passa trechos longos colada na linha da promessa e sobe, em surtos curtos, até cruzar a linha pontilhada. E os blocos têm data: o teto dos mundos que nunca mudam é cruzado em 6 episódios distintos, que ocupam 1,951% dos blocos medidos, em 2007, 2008, 2011, 2018 e 2020. Nem todos esses anos têm nome de crise, e todos aconteceram neste mercado.

A leitura do bloco corrige ainda a primeira impressão: 13,05% dos blocos passam do dobro da promessa. O que se promete não é o que se entrega, nem na maior parte do tempo, nem nos piores pedaços: é uma média entre os dois.

1.5 O preço muda de lugar

Se o corte assina a média, uma saída parece evidente: escolher outra janela. Vale a pena tentar, e a tentativa é barata, porque é a mesma regra com outro número. Varremos a janela de um mês a cinco anos, mantendo a promessa anunciada de 5% e o bloco de 60 dias.

As três colunas respondem à pergunta do começo.

A **conta do corte** obedece à promessa anunciada apenas na janela longa. Na janela de um mês, o corte assina 9,091%, quase o dobro dos 5% anunciados, e a razão é aritmética, não mercado: com poucos dias não existe corte que produza 5%.

janela (pregões)	a conta do corte (%)	a entrega (%)	o pior bloco (violações)
21	9,091	9,407	12
63	6,25	6,612	15
252	5,138	5,135	20
1260	4,996	5,093	24

Table 1.1: A mesma regra com quatro janelas, a mesma promessa anunciada de 5% e o mesmo bloco de 60 dias. A coluna do meio é a conta da Teorema 1.1; a última é o pior bloco medido.

A **entrega** acompanha a conta do corte nas quatro janelas, um pouco acima dela em todas. Esse resto é a contribuição do mundo, e é pequeno. Encurtar a janela não deixa a medida mais fina; torna a promessa mais caro do que se anunciou.

O **pior bloco** caminha no sentido oposto: 12, 15, 20, 24. Quanto mais longo o passado que a linha olha, mais tempo ela leva para acompanhar o que mudou, e mais violações cabem no pedaço ruim. Na janela de cinco anos o pior bloco chega a 24. No extremo oposto, uma janela curta não compra bloco nenhum: o pior bloco do mundo real, 12, fica *abaixo* do pior bloco de um mundo que nunca muda, porque uma janela curta se move junto com o mercado — e cobra o preço na média.




Figure 1.2: As duas leituras, nas quatro janelas. À esquerda, a média: a conta do corte e o mundo real andam juntos. À direita, o pior bloco: o mundo real contra o pior dos 200 mundos que nunca mudam.

Encurtar o corte cobra na média; alongá-lo cobra no bloco. Não há janela em que a linha entregue o que a promessa anunciou, e a razão disso é a Teorema 1.1, que não deixa o mundo entrar na conta.

1.6 Uma linha erguida no passado

Um corte fixo supõe que o pedaço de passado que ele olha se parece com o pedaço que vem. A série deste capítulo não se parece consigo mesma: passa meses colada na linha e depois rompe a linha 20 vezes em 60 dias, com o pior bloco terminando em 20 de novembro de 2008.

Quando isso acontece, a linha não erra por pouco. Ela foi erguida com os dias de antes,

e são justamente esses dias que deixaram de valer. A Table 1.1 já mostrava o mesmo por outro caminho: quanto mais longo o passado que a linha olha, mais tempo ela leva para acompanhar o que mudou, e mais violações cabem no pedaço ruim.

Se os blocos têm data, alguma coisa no mundo não é fixa, e a média não é o instrumento que a vê. Resta medir essa mudança, e é o que os capítulos seguintes fazem.

Capítulo 2

O orçamento do alarme

2.1 O vigia

O capítulo anterior deixou um instrumento e um incômodo. O instrumento conta quantas vezes o preço rompeu a linha dentro de uma janela móvel de 60 dias. O incômodo é que os blocos têm data: a contagem sobe nos mesmos anos, e sobe sempre no mesmo lugar da série.

A tentação, agora, é pequena e razoável. Se o bloco sabe *quando* o mundo aperta, basta ligar nele um alarme: soa quando a contagem passa de um limiar. E o limiar já vem escolhido por medição, não por gosto, porque no capítulo anterior o pior bloco de duzentos mundos que nunca mudam chegou a 13 violações. Um número que o mundo parado nunca alcançou é um candidato honesto a linha de alarme.

Fica então o vigia mais simples que dá para escrever: *soa quando as violações dos últimos 60 dias chegam a 13*.

Duas perguntas decidem se isso vale alguma coisa, e o capítulo é sobre elas: com que frequência ele soa quando nada muda, e quanto tempo ele leva quando algo muda de verdade. As duas precisam de resposta junta, porque cada uma é paga com a outra.

2.2 Quanto ele soa quando nada muda

A primeira pergunta não se responde no mercado, porque no mercado não se sabe quais alarmes eram falsos. Sabe-se que houve alarme, e só. Responde-se em mundos em que nada muda: 1000 séries do tamanho da nossa, com retornos independentes e sempre a mesma lei, submetidas ao mesmo corte, aos mesmos blocos e ao mesmo limiar.

No limiar 13, essas mil séries produziram 0,032 dia de alarme por mundo — quase nada —, e 0,6% dos mundos soaram pelo menos uma vez ao longo de vinte e cinco anos. Dito em tempo: o vigia soa sozinho uma vez a cada 3632 anos.

Um número desses pede desconfiança, e a desconfiança aqui é aritmética. Ele se apoia em 7 alarmes espalhados por 1000 mundos; contar evento raro é impreciso, e o erro relativo dessa contagem é de 37,8%. O que a medição entrega é a ordem de grandeza — milhares de anos —, e não o número exato.

Há um jeito de conferir esse orçamento sem sortear nada, e ele cabe numa proposição, porque a conta é uma união de acontecimentos.

Proposição 2.1 (o teto independente). *Se os dias fossem independentes, com probabilidade p de violar o corte em cada dia, então a probabilidade de algum bloco de B dias atingir L violações não passaria de $n \cdot \mathbb{P}(\text{Bin}(B, p) \geq L)$, onde n é o número de blocos.*

Prova. O acontecimento *algum bloco atinge o limiar* é a união, sobre os n blocos, dos acontecimentos *este bloco atinge o limiar*. A probabilidade de uma união nunca excede a soma das probabilidades dos seus termos, e sob independência a probabilidade de um bloco atingir L violações é a cauda da binomial. $\square$

Com os números deste capítulo o teto dá 5,879%, e o mundo parado mediu 0,6%. O teto está acima do medido, como tinha de estar, e está acima por quase uma dezena de vezes: é um limite provado e frouxo, e vale pelo que prova.

Ele também tem prazo de validade, e o prazo aparece na própria conta. Para limiares baixos a soma das parcelas ultrapassa cem por cento, e um teto de cento e vinte por cento não é teto de nada.

2.3 Quanto ele demora quando algo muda

O orçamento sozinho não decide nada. A pergunta que decide é a outra: quando o mundo muda, o vigia avisa a tempo de quê?

Na série inteira, e no mesmo limiar, ele soou 7 vezes em vinte e cinco anos, uma a cada 3,632 anos. No mundo parado o mesmo vigia soa uma vez a cada 3632 anos, ou 1000 vezes mais raro. Quem soa uma vez a cada três anos e meio num mundo que muda está respondendo ao mundo, e não ao próprio ajuste.

Para medir a que ele responde, cada alarme é comparado com o topo anterior e o fundo seguinte — o preço mais alto antes do tombo e o mais baixo depois —, e a conta que interessa é quanto do prejuízo total já tinha acontecido no dia do aviso.

Nos dois tombos maiores do período, o resultado é este.

	atraso desde o topo	prejuízo já pago
alarme de 22 de outubro de 2008	357 dias	74,77%
alarme de 18 de março de 2020	28 dias	86,01%

Table 2.1: Os dois piores tombos do período, com o dia do alarme e a fração do prejuízo total que já tinha acontecido quando ele soou. No tombo mais recente, o alarme veio com 29,18% de queda já realizada, de um total de 33,92%.

A mediana dos 7 alarmes é de 83,18% de prejuízo já pago. Num deles o alarme soou no fundo exato, com 100% do tombo consumido: o vigia avisou no dia em que a queda acabou.

Vale dizer do modo mais direto possível. O vigia acerta: os alarmes dele são reais, e o mundo parado quase nunca o faz soar. O que ele não faz é chegar antes.

2.4 A troca

Se o vigia é tardio, a saída parece óbvia: baixar o limiar. Baixar o limiar antecipa o alarme e cobra por isso, e o que vale medir é quanto, porque o preço tem forma.

Para cada limiar medimos as duas coisas de uma vez: a frequência com que ele soa em mundo parado, e quanto do prejuízo já estava pago quando ele soou no tombo recente.

A tabela diz três coisas.

A troca existe, e o primeiro passo é barato. Baixar o limiar de 13 para 8 derruba o prejuízo já pago de 86,01% para 36,02%: o vigia passa a avisar antes de o tombo se completar.

limiar (violações)	um alarme falso a cada (anos de mundo parado)	prejuízo já pago no tombo recente (%)
8	4,145	36,02
9	12,57	55,68
10	41,75	56,13
11	170,6	78,83
12	747,8	87,05
13	3632	86,01

Table 2.2: A troca, medida. Baixar o limiar antecipa o alarme e multiplica o falso alarme; a taxa de câmbio não é constante, e piora à direita da tabela.

O preço desse passo é brutal. O mesmo movimento leva o falso alarme de um a cada 3632 anos de mundo parado para um a cada 4,145 anos. O vigia que quase nunca se enganava passa a soar a cada poucos anos sem que nada tenha mudado.

E a taxa de câmbio piora na outra ponta. Do limiar 10 para o 12, o falso alarme fica quase vinte vezes mais raro e o prejuízo já pago quase não se move: 56,13% contra 87,05%. Paga-se muito por nada, e há dois limiares vizinhos entregando exatamente a mesma coisa.




Figure 2.1: A troca em forma de curva: o eixo horizontal é a raridade do falso alarme, em escala logarítmica, e o vertical é o prejuízo já pago no tombo recente. A curva sobe depressa na esquerda e achata na direita.

Não existe limiar que seja ao mesmo tempo raro e rápido. O vigia é o par — frequência em mundo parado e atraso em mundo que muda —, e escolher um limiar é escolher um ponto dessa curva, com o preço da esquerda pago em falso alarme e o da direita pago em atraso.

2.5 O piso

Antes de concluir que o vigia está mal calibrado, vale olhar o chão em que ele está, porque o atraso dele tem piso, e o piso é aritmético.

Proposição 2.2 (o piso do atraso). *Um alarme que exige L violações dentro da janela móvel não pode soar antes de L pregões depois de a mudança começar, se antes dela o corte não era violado.*

Prova. Para que a contagem chegue a L , são necessários ao menos L dias com violação dentro da janela. Cada dia com violação consome um pregão, e nenhum deles pode ser anterior ao começo da mudança. Logo o alarme exige ao menos L pregões. $\square$

Com $L = 13$, o piso é de 13 pregões. O alarme de 18 de março de 2020 soou 28 dias corridos depois do topo, poucos pregões mais do que o piso: o vigia não estava gastando tempo à toa, estava esperando a contagem encher, que é o que ele sabe fazer.

A consequência é dura para quem queria melhorar o vigia ajustando números. A única alavanca é o próprio limiar, e o limiar é o orçamento; comprar velocidade é pagar em falso alarme, na taxa de câmbio da Table 2.2.




Figure 2.2: O alarme de 18 de março de 2020 visto dos dois lados. Em cima, o índice; embaixo, as violações dos 60 dias anteriores, com o limiar. As duas linhas contam a mesma história — e a de baixo conta depois da de cima.

2.6 O mesmo corte, lido mais fundo

Tudo o que foi medido até aqui é uma leitura do corte do capítulo anterior: contar quantas vezes o preço rompeu a linha, e alarmar quando a contagem enche. O corte admite uma segunda leitura, mais direta, e vale olhá-la antes de aceitar que o vigia é assim mesmo.

Nessa leitura o alarme não espera contagem nenhuma. Ele soa no dia em que o preço fica abaixo do k -ésimo pior dos últimos n dias; com $k = 1$, soa no dia em que o preço faz o pior dia do último ano. É o mesmo corte, com o posto escolhido de outro jeito, e dessa vez a escolha tem conta fechada, porque é a proposição do capítulo anterior lida ao contrário: o posto k com janela n assina a taxa $k/(n + 1)$.

Isso muda a natureza do orçamento. Na leitura do bloco, a frequência do falso alarme não tem forma fechada — sessenta blocos móveis se sobrepõem, e o melhor que se consegue é medir, com o erro de contagem que a Teorema 2.1 limita por cima. Na leitura do dia a frequência é exata, e o número declarado é o número entregue: nos mundos que nunca mudam, a medição devolveu 25,66 alarmes contra os 25,56 que a conta declara.

Daí sai um limite que calibração nenhuma contorna. O posto mais fundo possível é o primeiro da fila, de modo que com n dias de memória o alarme mais raro que existe é $1/(n+1)$. Um alarme por ano custa 252 dias de memória; um alarme por década custa 2520 dias, que são dez anos de série, e quem não tem esses dias não tem esse alarme.

O que essa leitura compra é tempo. No orçamento de 0,996 alarme por ano, ela avisou do tombo recente em 24 de fevereiro de 2020, com 13,95% do prejuízo já pago, contra os 86,01% da leitura do bloco. No tombo antigo, avisou em 9 de setembro de 2008 com 38,33%, contra 74,77% da outra leitura.

A comparação, porém, pede cuidado, porque os dois vigias foram declarados em orçamentos diferentes: 0,996 alarme por ano de um lado, um a cada 3632 anos do outro. No ponto em que os dois orçamentos se aproximam, a vantagem some. Com 0,1998 alarme por ano, ou um a cada cinco anos, a leitura do dia chegou ao tombo recente em 27 de fevereiro de 2020 com 35,46% do prejuízo pago; a leitura do bloco, no limiar 8, soa uma vez a cada 4,145 anos e chega com 36,02%. Duas leituras do mesmo corte, o mesmo silêncio, quase o mesmo preço.

E a leitura do dia tem um preço próprio, que a tabela do bloco não mostra. Num mundo que nunca muda ela soa, por construção, na taxa que declarou: declarar 0,996 alarme por ano é aceitar 33 alarmes em vinte e cinco anos, ou 1,286 por ano, enquanto o vigia do bloco soou 7 vezes no mesmo período. A escolha é entre um vigia que fala 1,286 vezes por ano e chega cedo, e um vigia que fala uma vez a cada três anos e meio e chega depois.

2.7 A forma decide o preço

Falta uma peça, e ela é grande. Toda a medição de atraso feita até aqui usou os tombos que aconteceram, e tombo é uma forma só de mudança: a cauda se abre de repente, e o dia ruim é enorme. O mundo muda de outras maneiras.

Para medir isso sem depender de quais tombos o mercado ofereceu, usamos mundos em que a mudança é posta de propósito, com data conhecida: séries de 3000 dias em que a oscilação muda no dia 1500, e 200 repetições de cada forma. São três.

- o **degrau** — a oscilação dobra de uma vez, e a partir dali fica assim;
- a **rampa** — a oscilação cresce até dobrar ao longo de meses, de modo que nenhum dia isolado é extraordinário;
- a **deriva** — a média se desloca um pouco a cada dia, sem que a oscilação mude em nada.

Mesma rotina, mesmo orçamento, e o resultado é uma diferença que nenhum ajuste de limiar resolve.

No orçamento de 0,996 alarme por ano, o degrau foi visto em 7 dias, a rampa em 69 dias e a deriva em 149,5 dias. Encurtando a memória para um mês, o orçamento fica falador (11,45 alarme por ano) e as três formas chegam quase juntas: o degrau em 3 dias, a rampa em 12 e a deriva em 12,5.

A leitura da figura é a leitura dos números. Com um orçamento raro, a mudança que o vigia vê depressa é a cauda que se abre de uma vez, e a que ele vê devagar é a média que




Figure 2.3: Dias até o primeiro alarme, por forma de mudança, em dois orçamentos: a memória de um mês, à esquerda de cada par, e a de um ano, à direita. O orçamento mais raro paga a diferença entre as formas.

se desloca: a mesma rotina, o mesmo silêncio prometido, e 149,5 dias contra 7. Com um orçamento falador, a distância entre as formas quase desaparece, porque um alarme que soa a cada poucos dias não precisa esperar por nada.

Isso também diz o que a Table 2.2 de fato mediu. A curva da troca foi desenhada com os tombos do mercado, que são degraus; para uma deriva, a mesma curva estaria deslocada para a direita, com o preço do silêncio pago em meses.

2.8 O que a memória faz

O corte é erguido com os dias que já passaram, e por isso ele acompanha o mundo. Poucos dias depois de um degrau na oscilação, os piores dias da janela já são dias mudados, e o corte desce junto com eles. Num mundo que passa a oscilar oito vezes mais, a contagem em 60 dias assenta em 3,093, onde a promessa admite 3 — e o mundo segue oito vezes mais perigoso.

Vale comparar com o corte que não se mexe. Erguido uma vez e deixado parado, ele continua medindo o mundo novo com a régua velha: a contagem assenta em 25,03, oito vezes a promessa, e não volta. No mundo parado os dois cortes dão a mesma coisa, 3,336 contra 3,079, de modo que a diferença entre eles não é de calibração. É de memória.

A promessa se sustenta porque a memória esquece. O mesmo movimento que restaura a taxa apaga a mudança, e um vigia feito dessa taxa fica sem o que ver depois que a janela se renova: no degrau isso custa uma dúzia de dias, e na rampa, 117 dias para o mesmo tamanho final. A forma não muda o que aconteceu ao mundo. Muda o que sobra para o vigia ver.

A deriva escapa aos dois cortes. Deslocar a média não mexe na oscilação, e a contagem sente pouco: no corte fixo, uma deriva de 50,4% ao ano leva a contagem de 3,336 para 4,556, quase nada, porque um passo de dois décimos por cento contra um barulho de um por cento por dia mal move a cauda esquerda.

Para essa forma existe outro instrumento, e ele mede outra coisa: a média da janela

em erros-padrão dela mesma (`centro.py`). Ele vê a deriva forte em 202 dias, com 8,333% dos mundos sem alarme nenhum no horizonte de 500 dias. E é cego à escala: nos mundos de degrau e de rampa ele não soa em quase oitenta por cento dos casos, porque dobrar a oscilação dobra o erro-padrão da média e deixa a estatística onde estava.

A demora dele se paga em memória, e a conta fecha em duas linhas. Uma regra de L erros-padrão vê uma deriva de passo p contra um barulho σ quando a janela tem $(L\sigma/p)^2$ dias — e a latência mínima é esse mesmo número, porque o instrumento precisa dos dias antes de poder julgá-los. Com um ano de memória, a regra enxerga a deriva que o barulho esconde por um fator de $\sqrt{252}$; com catorze anos, uma quatro vezes menor. Para a deriva de 12,6% ao ano deste capítulo, a memória exigida é de 3600 dias: no horizonte de 500 dias nenhum mundo alarmou, e o motivo não é cegueira. É que a memória que ele pede é maior do que o tempo que se esperou.




Figure 2.4: Quatro mundos de quarenta anos, cada um com a sua mudança no meio (linha pontilhada). Em cima, o retorno acumulado; embaixo, os rompimentos do corte em 60 dias, com o limiar do vigia. A deriva é o único mundo que cai, e é o único em que a contagem não sobe.

2.9 O que fica

O que fica é o orçamento, e ele fixa uma coisa só: **todo alarme é um par declarado** — com que frequência ele soa quando nada muda, e quanto ele demora quando algo muda. Um alarme que não declara o par não é uma afirmação; é barulho com opinião. Fica também a moeda do par: ele se compra com memória, porque o alarme mais raro que n dias de janela permitem é $1/(n+1)$, e se paga conforme a forma da mudança, que decide quantos dias custa sair do silêncio.

E fica o fracasso seguinte, que é o mais fundo até aqui. O capítulo mediu três formas de

mudança na mesma série — a cauda que se abre de uma vez, a cauda que se aproxima em rampa, e a média que se desloca — e precisou de dois instrumentos para isso: a contagem de rompimentos, que vê as duas primeiras e é cega à terceira, e a média da janela medida em erros-padrão dela mesma, que vê a deriva e é cega à escala.

As outras duas formas que o mundo tem não aparecem em nenhum dos dois. A dependência entre duas séries pode mudar sem que nenhuma das duas mude de tamanho, e o calendário pode passar a juntar as coisas ruins na mesma semana sem que nenhum dia fique maior: não há dia para romper a linha, e não há limiar que veja. Medir essas formas exige um terceiro instrumento, e é a pergunta seguinte.

Fontes

- [1] G. A. Carpenter, S. Grossberg. A massively parallel architecture for a self-organizing neural pattern recognition machine. Boston University; Northeastern University, 1987.
- [2] Stephen Grossberg. Competitive Learning: From Interactive Activation to Adaptive Resonance. Boston University (CNS Tech Lab), 1987.
- [3] D. E. Rumelhart, D. Zipser. Feature discovery through competitive learning. University of California at San Diego, 1985.
- [4] T. J. Sejnowski, C. R. Rosenberg. NETtalk: A parallel-network that learns to read aloud. Johns Hopkins University, 1986.
- [5] Thomas Bayes, Richard Price. An Essay towards solving a Problem in the Doctrine of Chances. Royal Society, 1763.
- [6] Norman Dalkey, Olaf Helmer. An Experimental Application of the Delphi Method to the Use of Experts. RAND Corporation, 1962.
- [7] Judea Pearl. Bayesian Networks*. University of California, Los Angeles (UCLA), 2000.
- [8] Stefan Conrady, Lionel Jouffe. Bayesian Networks & BayesiaLab: A Practical Introduction for Researchers. BayesiaLab (Bayesia), 2015.
- [9] David Aebischer, John Vatterott, Jr., Michael Grimes, Andrew Vatterott, Roderick Jordan, Carlo Reinoso, Bradford Alex Baker, William D. Aldrich, Luis Reinoso, Rodolfo Villalba, Michael Johnson, Christopher Myers, Stefan Conrady, Joseph A. Tatman, Suzanne M. Mahoney, Darrin L. Whaley, Amanda B. Hepler. Bayesian Networks for Combat Equipment Diagnostics. U.S. Army Communications Electronics Command, Aberdeen, Maryland, 2017.
- [10] Stefan Conrady. Exchange-Traded Funds: Knowledge Discovery, Interpretation, and Anomaly Detection. Bayesia USA, 2018.
- [11] Andrea Fontanari, Pasquale Cirillo, Nassim Nicholas Taleb. Gini Estimation Under Infinite Variance. STEM Academic Press, 2020.
- [12] Nassim Nicholas Taleb, Michail Loulakis, Spyros Makridakis, Pasquale Cirillo. How Much Data Do You Need? An Operational Metric for Fat-Tailedness. STEM Academic Press, NYU Tandon School of Engineering, 2020.
- [13] Nassim Nicholas Taleb, Raphael Douady. On the Super-Additivity and Estimation Biases of Quantile Contributions. STEM Academic Press, 2020.

- [14] Nassim Nicholas Taleb, Brandon Yarckin, Chitpuneet Mann, Damir Delic, Mark Spitznagel. Option Pricing Under Power Laws: A Robust Heuristic. Universa Investments, STEM Academic Press, 2020.
- [15] Vladimir Vovk, Bin Wang, Ruodu Wang. Admissible ways of merging p-values under arbitrary dependence. University of London, University of Waterloo, 2022.
- [16] Hongjian Wang, Aaditya Ramdas. Anytime-valid t-tests and confidence sequences for Gaussian means with unknown variance. Carnegie Mellon University, 2025.
- [17] Vladimir Vovk, Ruodu Wang. E-values: Calibration, combination, and applications. University of London, University of Waterloo, 2021.
- [18] Ian Waudby-Smith, Aaditya Ramdas. Estimating means of bounded random variables by betting. Carnegie Mellon University, 2024.
- [19] Ruodu Wang, Aaditya Ramdas. False discovery rate control with e-values. University of Waterloo, Carnegie Mellon University, 2022.
- [20] Martin Larsson, Aaditya Ramdas, Johannes Ruf. The numeraire e-variable and reverse information projection. Carnegie Mellon University, London School of Economics, 2025.
- [21] Larry Wasserman, Aaditya Ramdas, Sivaraman Balakrishnan. Universal inference. Carnegie Mellon University, 2020.
- [22] Ilya Prigogine. La Fin des Certitudes. Editions Odile Jacob, 1996.
- [23] Ilya Prigogine; Isabelle Stengers. The End of Certainty. University of Texas at Austin; Free University of Brussels, 1997.
- [24] Matthias Seeger. Bayesian Gaussian Process Models: PAC-Bayesian Generalisation Error Bounds and Sparse Approximations. University of Edinburgh, 2003.
- [25] Matthias Seeger, Christopher Williams, Neil Lawrence. Fast Forward Selection to Speed Up Sparse Gaussian Process Regression. University of Edinburgh, 2003.
- [26] Neil Lawrence, Matthias Seeger, Ralf Herbrich. Fast sparse Gaussian process methods: The informative vector machine. Microsoft Research, Cambridge; University of Edinburgh, 2003.
- [27] Matthias Seeger. PAC-Bayesian Generalization Error Bounds for Gaussian Process Classification. University of Edinburgh, 2002.
- [28] Nassim Nicholas Taleb. Machine Learning Considerations. NYU Tandon School of Engineering, 2020.
- [29] Nassim Nicholas Taleb, Pasquale Cirillo, Raphael Douady, Andrea Fontanari, Hélyette Geman, Donald Geman, Espen Haug. Statistical Consequences of Fat Tails: Real World Preasymptotics, Epistemology, and Applications. NYU Tandon School of Engineering, Universa Investments, 2020.
- [30] Henri Bergson. Essai sur les données immédiates de la conscience Time and Free Will. Lycée de Clermont-Ferrand, 1888.
- [31] Henri Bergson. Matter and Memory Matière et mémoire. Collège de France, 1896.

- [32] Mark B. N. Hansen. *New Philosophy for New Media*. Princeton University, 2004.
- [33] Brian Massumi. *Parables for the Virtual*. Université de Montréal, 2002.
- [34] Gustav Fechner. *The Elements of Psychophysics*. Universität Leipzig (Leipzig University), 1860.
- [35] Shibhansh Dohare, J. Fernando Hernandez-Garcia, Qingfeng Lan, Parash Rahman, A. Rupam Mahmood, Richard S. Sutton. *Loss of Plasticity in Deep Continual Learning*. University of Alberta, Amii, 2024.
- [36] Shibhansh Dohare, Qingfeng Lan, A. Rupam Mahmood. *Overcoming Policy Collapse in Deep Reinforcement Learning*. University of Alberta, 2023.
- [37] V. Farias, A. D. Jozefiak. *Self-Normalized Resets for Plasticity in Continual Learning*. Massachusetts Institute of Technology (MIT), 2025.
- [38] G. Sokar, R. Agarwal, P. S. Castro, U. Evci. *The Dormant Neuron Phenomenon in Deep Reinforcement Learning*. Eindhoven University of Technology; Google DeepMind; Mila, 2023.
- [39] Yang Song, Stefano Ermon. *Generative Modeling by Estimating Gradients of the Data Distribution*. Stanford University, 2019.
- [40] Jaehyeok Shin, Aaditya Ramdas, Alessandro Rinaldo. *E-detectors: a nonparametric framework for sequential change detection*. Carnegie Mellon University, 2022.
- [41] Jonas Peters, Peter Bühlmann, Nicolai Meinshausen. *Causal inference using invariant prediction: identification and confidence intervals*. ETH Zürich, University of Copenhagen, 2016.
- [42] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, Nan Rosemary Ke, Nal Kalchbrenner, Anirudh Goyal, Yoshua Bengio. *Toward Causal Representation Learning*. Max Planck Institute for Intelligent Systems, Mila, Google Research, 2021.
- [43] Vincent Plassier, Mehdi Makni, Aleksandr Rubashevskii, Eric Moulines, Maxim Panov. *Conformal Prediction for Federated Uncertainty Quantification Under Label Shift*. Ecole Polytechnique (France), Lagrange Mathematics and Computing Research Center, MBZUAI (EAU), Technology Innovation Institute, 2023.
- [44] C. Dong, C. Smadi, V. A. Vatutin. *Critical branching processes in random environment and Cauchy domain of attraction*. Xidian University (China), Univ. Grenoble Alpes (France), Steklov Mathematical Institute (Russia), 2020.
- [45] Topi Halme, H. Vincent Poor, Visa Koivunen. *Adaptive Sequential Change Detection using Mixtures of Predictive Distributions*. Aalto University, Princeton University, 2026.
- [46] Tero Karras, Miika Aittala, Timo Aila, Samuli Laine. *Elucidating the Design Space of Diffusion-Based Generative Models (EDM)*. NVIDIA, 2022.
- [47] Kevin Black, Cheng Chi, Abhishek Gupta, Sergey Levine. *Training Diffusion Models with Reinforcement Learning (DDPO)*. UC Berkeley, 2023.

- [48] E. Lemaire; L. Cordone; A. Castagnetti; P.-E. Novac et al.. An analytical estimation of spiking neural networks energy efficiency. Citado em estudo da Delft University of Technology, 2023.
- [49] Enrique Barba Roque; Luis Cruz. Energy Aware Development of Neuromorphic Implantables: From Metrics to Action. Delft University of Technology (TU Delft), 2025.
- [50] J. Yik; K. V. den Berghe; D. den Blanken; Y. Bouhadjar et al.. Neurobench: A framework for benchmarking neuromorphic computing algorithms and systems. Harvard University; Delft University of Technology; Forschungszentrum Jülich; IMEC Netherlands; City University of Hong Kong; Intel; Istituto Italiano di Tecnologia (colaboração multi-institucional), 2025.
- [51] Aaditya Ramdas. Hypothesis testing using e-values, martingales & betting. Carnegie Mellon University, 2021.
- [52] Roberto Alvarez-Martinez e Pedro Miramontes. Early Warning Signals in Ecological Time-Series. Universidad Autónoma de Querétaro; UNAM; Universidad Autónoma de San Luis Potosí, 2026.
- [53] Mark Braverman e Or Zamir. Optimality of Frequency Moment Estimation. Princeton University; Tel Aviv University, 2025.
- [54] Pasquale Cirillo e Nassim Nicholas Taleb. Tail Risk of Contagious Diseases. Delft University of Technology; New York University (Tandon School of Engineering), 2020.
- [55] Shashank Gupta, Chaitanya Ahuja, Tsung-Yu Lin, Sreya Dutta Roy, Harrie Oosterhuis, Maarten de Rijke, Satya Narayan Shukla. A Simple and Effective Reinforcement Learning Method for Text-to-Image Diffusion Fine-tuning. University of Amsterdam, Meta AI, Radboud University, 2026.
- [56] Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, Nan Rosemary Ke, Nal Kalchbrenner, Anirudh Goyal, Yoshua Bengio. Towards Causal Representation Learning. Max Planck Institute, Mila, Google Research, 2021.
- [57] James P Jun, Vijay Marupudi, Raj Sanjay Shah, Sashank Varma. A Neural Network Model of Complementary Learning Systems: Pattern Separation and Completion for Continual Learning. Georgia Institute of Technology, 2025.
- [58] Claudia Czado, Tilmann Gneiting, Leonhard Held. Predictive Model Assessment for Count Data. Technische Universität München, University of Washington, Universität Zürich, 2007.
- [59] David Woodruff. Optimal Space Lower Bounds for all Frequency Moments. MIT, CMU School of Computer Science, 2004.
- [60] Adam Paszke, Micha Pilipczuk. VC Density of Set Systems Definable in Tree-Like Graphs. University of Warsaw, 2020.
- [61] Andrei Nikolaevich Kolmogorov. Grundbegriffe der Wahrscheinlichkeitsrechnung. Moscow State University, 1933.
- [62] Preetha Ramiah, James Q. Smith, Silvia Liverani, Jamie Addison, Annabel Whipp, Oliver Bunnin. Bayesian Graphs of Intelligent Causation. Queen Mary University of London, University of Warwick, The Alan Turing Institute, Dstl, 2024.

- [63] Xi Chen, Yining Wang, Yu-Xiang Wang. Non-stationary Stochastic Optimization under $L_{\{p,q\}}$ -Variation Measures. Stern School of Business (NYU), Carnegie Mellon University, Amazon Inc., 2018.
- [64] Vladimir Vovk, Alex Gammerman, Glenn Shafer. Algorithmic learning in a random world. Royal Holloway (University of London), Rutgers School of Business, 2022.
- [65] Borja Sánchez-López, Jesus Cerquides. Dual Stochastic Natural Gradient Descent and convergence of interior half-space gradient approximations. IIIA-CSIC, Campus UAB, Bellaterra (Spain), 2021.
- [66] Juraj Bodik, Valérie Chavez-Demoulin. Structural restrictions in local causal discovery: identifying direct causes of a target variable. HEC, Université de Lausanne, 2025.
- [67] Suhas Thejaswi, Clemens Westrup. Approximate Computation of Frequency Moments. Aalto University, 2016.
- [68] Stephen Grossberg. A Path Toward Explainable AI and Autonomous Adaptive Intelligence: Deep Learning, Adaptive Resonance, and Models of Perception, Emotion, and Action. Center for Adaptive Systems, Boston University, 2020.
- [69] Velez e Clune. Diffusion-based neuromodulation can eliminate catastrophic forgetting in simple neural networks. Computer Science Department, University of Wyoming; Uber AI Labs, 2017.
- [70] Kirkpatrick et al.. Overcoming catastrophic forgetting in neural networks. Google DeepMind (United Kingdom); Imperial College London, 2017.
- [71] Song et al.. Consistency Models. OpenAI, 2023.
- [72] Kim et al.. Consistency Trajectory Models: Learning Probability Flow ODE Trajectory of Diffusion (CTM). KAIST, 2024.
- [73] Yin et al.. Improved Distribution Matching Distillation for Fast Image Synthesis (DMD2). MIT, Adobe, 2024.
- [74] Song & Dhariwal. Improved Techniques for Training Consistency Models (iCT). OpenAI, 2023.
- [75] Kaiwen Zheng, Yuji Wang, Qianli Ma, Huayu Chen, Jintao Zhang, Yogesh Balaji, Jianfei Chen, Ming-Yu Liu, Jun Zhu, Qinsheng Zhang. Large Scale Diffusion Distillation via Score-Regularized Continuous-Time Consistency (rCM). Alibaba (Wan 2.1), NVIDIA (Cosmos), 2025.
- [76] Yin et al.. One-step Diffusion with Distribution Matching Distillation (DMD). MIT, Adobe, 2024.
- [77] Lu & Song. Simplifying, Stabilizing and Scaling Continuous-Time Consistency Models (sCM / TrigFlow). OpenAI, 2024.
- [78] Jonathan Ansari, Ludger Rüschendorf. Sklar’s theorem, copula products, and ordering results in factor models. University of Freiburg, 2021.

- [79] Alexander Ly, Udo Boehm, Peter Grünwald, Aaditya Ramdas, Don van Ravenzwaaij. A Tutorial on Safe Anytime-Valid Inference: Practical Maximally Flexible Sampling Designs for Experiments Based on e-Values. Centrum Wiskunde & Informatica, Tilburg University, Leiden University, Carnegie Mellon, University of Groningen, 2023.
- [80] Albert-László Barabási, Réka Albert, Carlson, Doyle, Perdomo, Hardt, Peters, Bühlmann, Meinshausen. Redes Complexas, Criticidade e Transições de Regime: Uma Síntese Rigorosa de Topologia, Dinâmica de Bifurcação, Performatividade e Invariância Causal. s.d..
- [81] Marten Scheffer, Stephen R. Carpenter. Catastrophic regime shifts in ecosystems: linking theory to observation. Wageningen University, University of Wisconsin, 2003.
- [82] Ralf Herbrich, Thore Graepel. A PAC-Bayesian Margin Bound for Linear Classifiers: Why SVMs work. Technical University of Berlin, 2000.
- [83] PabloAMC, Jaime Sevilla, Victor Veitch, Claudia Shi, Zhijing Jin. Causal representation learning as a technique to prevent goal misgeneralization. AI Alignment Forum, University of Oxford, DeepMind, Columbia University, Max Planck, ETH, UC Berkeley, 2023.
- [84] Simon Bing, Jonas Wahl, Urmi Ninad, Jakob Runge. Invariance & Causal Representation Learning: Prospects and Limitations. Technische Universität Berlin, German Aerospace Center (DLR), 2023.
- [85] Zhaoyu Zhu, Rui Gao, Shuang Li. Wasserstein Policy Gradient for Entropy-Regularized Linear-Quadratic Control. University of Illinois Urbana-Champaign, University of Texas at Austin, Chinese University of Hong Kong, 2026.
- [86] Julien Bastian, Benjamin Leblanc, Pascal Germain, Amaury Habrard, Christine Largeron, Guillaume Metzler, Emilie Morvant, Paul Viallard. PAC-Bayesian Generalization Guarantees for Fairness on Stochastic and Deterministic Classifiers. Université Jean Monnet Saint-Étienne, Université Laval, Univ Rennes, 2026.
- [87] Annalisa Di Clemente, Claudio Romano. Calibrating and Simulating Copula Functions in Financial Applications. Sapienza University of Rome, 2021.
- [88] Ryan O’Connell. Extreme Value Theory in Finance: Tail Risk, GEV, and GPD. Ryan O’Connell Finance LLC, 2026.
- [89] Haoze Li, Jun Xie. Feature Matching Intervention: Leveraging Observational Data for Causal Representation Learning. Purdue University, 2025.
- [90] Juan C. Perdomo, Tijana Zrnic, Celestine Mendler-Dünner, Moritz Hardt. Performative Prediction. University of California, Berkeley, 2020.
- [91] Xu, Xie. Wasserstein-Regularized Conformal Prediction under General Distribution Shift. The Hong Kong University of Science and Technology (Guangzhou); Harbin Institute of Technology; Lehigh University, 2025.
- [92] Ah-hwee Tan. Adaptive resonance associative map. National University of Singapore / Singapore Management University, 1995.

- [93] Takaaki Koike, Marius Hofert, Haruki Tsunekawa. Measuring multivariate maximal tail dependence. Hitotsubashi University, University of Hong Kong, 2026.
- [94] Samantha Fairchild, Max Goering, Christian Wei. FAMILIES OF WELL APPROXIMABLE MEASURES. University of Washington, Ruhr West University of Applied Sciences, 2021.
- [95] Yi-Yu Lin. Sklar’s Theorem and Quantum State Reconstruction from All-Context Dependence. Fudan University, Shanghai Institute for Mathematics and Interdisciplinary Sciences (SIMIS), 2026.
- [96] Zhanglu Yan, Zhenyu Bai, Kaiwen Tang, Weng-Fai Wong. Reconsidering the Energy Efficiency of Spiking Neural Networks Inference from Analytical Perspectives. National University of Singapore (NUS), 2026.
- [97] Carlos Sebastián, Carlos E. González-Guillén, Jesús Juan. Enhancing reliability in prediction intervals using point forecasters: Heteroscedastic Quantile Regression and Width-Adaptive Conformal Inference. Fortia Energía, Universidad Politécnica de Madrid, 2025.
- [98] Alison L. Gibbs, Francis Edward Su. On choosing and bounding probability metrics. York University, Harvey Mudd College, 2002.
- [99] Omar Rivasplata, Ilja Kuzborskij, Csaba Szepesvári, John Shawe-Taylor. PAC-Bayes Analysis Beyond the Usual Bounds. University College London, DeepMind, Amii, 2020.
- [100] Kevin Black, Michael Janner, Yilun Du, Ilya Kostrikov, Sergey Levine. Training Diffusion Models with Reinforcement Learning. University of California, Berkeley; MIT, 2024.
- [101] J. Choi, J. Choi, M. Kang. Generative modeling through the semi-dual formulation of unbalanced optimal transport. Seoul National University, 2023.
- [102] P. Mokrov, A. Korotin, L. Li, A. Genevay, J. M. Solomon, E. Burnaev. Large-scale wasserstein gradient flows. Skolkovo Institute of Science and Technology, MIT, 2021.
- [103] Jaemoo Choi, Jaewoong Choi, Myungjoo Kang. Scalable Wasserstein Gradient Flow for Generative Modeling through Unbalanced Optimal Transport. Seoul National University, Korea Institute for Advanced Study, 2024.
- [104] Ulrike von Luxburg, Bernhard Schölkopf. Statistical Learning Theory: Models, Concepts, and Results. Max Planck Institute for Biological Cybernetics, 2008.
- [105] Glenn Shafer, Vladimir Vovk. The Sources of Kolmogorov’s Grundbegriffe. Rutgers Business School, Royal Holloway University of London, 2006.
- [106] E. de Amo, M. Díaz Carrillo, J. Fernández-Sánchez. Characterization of all copulas associated with non-continuous random variables. University of Almería, University of Granada, 2012.
- [107] Vladimir Vapnik, Alexey Chervonenkis. Vapnik–Chervonenkis dimension. 2026.
- [108] Simon Pope, Audun Jsang. Analysis of Competing Hypotheses using Subjective Logic. The University of Queensland, DSTC Pty Ltd, 2005.

- [109] Ryan J. Tibshirani, Rina Foygel Barber, Emmanuel J. Candès, Aaditya Ramdas. Conformal Prediction Under Covariate Shift. Stanford University, University of Chicago, Carnegie Mellon University, 2019.
- [110] Rainer Dahlhaus. The Estimation of Parameter Curves for Locally Stationary Processes. Universität Heidelberg, 1997.
- [111] Audun Jsang. Cumulative and Averaging Fission of Beliefs. UniK, University of Oslo, 2007.
- [112] Matthias Seeger. Bayesian Gaussian Process Models: PAC-Bayesian Generalization Error Bounds and Sparse Approximations. University of Edinburgh, 2003.
- [113] Motonobu Kanagawa, Philipp Hennig, Dino Sejdinovic, Bharath K. Sriperumbudur. Gaussian Processes and Kernel Methods: A Review on Connections and Equivalences. University of Tübingen; Max Planck Institute for Intelligent Systems; University of Oxford; Pennsylvania State University, 2018.
- [114] Jeremy Bernstein, Alex Farhang, Yisong Yue. Kernel Interpolation as a Bayes Point Machine. Caltech, 2022.
- [115] Matthias Seeger. PAC-Bayesian generalization bounds for gaussian processes. University of Edinburgh (Division of Informatics), 2002.
- [116] Matthieu Garcin, Maxime L. D. Nicolas. Nonparametric estimator of the tail dependence coefficient: balancing bias and variance. Léonard de Vinci Pôle Universitaire, Université Paris I Panthéon-Sorbonne, 2026.
- [117] Kwonho Kim, Heejeong Nam, Inwoo Hwang, Sanghack Lee. Towards Causal Representation Learning with Observable Sources as Auxiliaries. Seoul National University, Brown University, Columbia University, 2025.
- [118] Alexander Mey, Rui Manuel Castro. Invariant Causal Prediction with Locally Linear Models. Eindhoven University of Technology (TU/e), ASML Research, 2024.
- [119] Willem Anna Mark Wybo. Using the Green’s function to simplify and understand dendrites. EPFL (École Polytechnique Fédérale de Lausanne), 2017.
- [120] Wilfredo Palma, Ricardo Olea. An efficient estimator for locally stationary Gaussian long-memory processes. Pontificia Universidad Católica de Chile, 2010.
- [121] Rainer Dahlhaus. Locally stationary processes. Universität Heidelberg, 2012.
- [122] Rainer Dahlhaus, Wolfgang Polonik. Nonparametric quasi maximum likelihood estimation for Gaussian locally stationary processes. Universität Heidelberg, University of California, 2006.
- [123] Rainer Dahlhaus, L. Giraitis. On the optimal segment length for parameter estimates for locally stationary time series. Universität Heidelberg, 1998.
- [124] Wilfredo Palma, Ricardo Olea, Guillermo Ferreira. Estimation and forecasting of locally stationary processes. Sociedad Chilena de Estadística, 2013.
- [125] Linbo Wang, Thomas Richardson, James Robins. Causal Inference: A Tale of Three Frameworks. University of Toronto, University of Washington, Harvard T.H. Chan School of Public Health, 2025.

- [126] Rabanus Derr, Robert C. Williamson. Systems of Precision: Coherent Probabilities on Pre-Dynkin-Systems and Coherent Previsions on Linear Subspaces. University of Tübingen, Tübingen AI Centre, 2023.
- [127] Frank Lad, Giuseppe Sanfilippo, Gianna Agrò. Extropy: Complementary Dual of Entropy. University of Canterbury (NZ), University of Palermo (Italy), 2015.
- [128] AmirEmad Ghassami, Saber Salehkaleybar, Negar Kiyavash, Kun Zhang. Learning Causal Structures Using Regression Invariance. University of Illinois at Urbana-Champaign, Carnegie Mellon University, 2017.
- [129] Macaluso Girolamo, Mandelli Lorenzo, Mirko Bicchierai, Stefano Berretti, Andrew D. Bagdanov. No MoCap Needed: Post-Training Motion Diffusion Models with Reinforcement Learning using Only Textual Prompts. University of Florence, 2025.
- [130] Lihua Lei, Emmanuel J. Candès. Conformal Inference of Counterfactuals and Individual Treatment Effects. Stanford University, 2021.
- [131] Badr-Eddine Chérif-Abdellatif, Pierre Alquier, Mohammad Emtiyaz Khan. A Generalization Bound for Online Variational Inference. CREST, ENSAE, Institut Polytechnique de Paris; RIKEN Center for AI Project, 2019.
- [132] Allen Z. Ren, Justin Lidard, Lars L. Ankile, Anthony Simeonov, Pulkit Agrawal, Anirudha Majumdar, Benjamin Burchfiel, Hongkai Dai, Max Simchowitz. Diffusion Policy Policy Optimization. Princeton University; Massachusetts Institute of Technology; Toyota Research Institute; Carnegie Mellon University, 2024.
- [133] James L McClelland. Incorporating rapid neocortical learning of new schema-consistent information into complementary learning systems theory. Stanford University, 2013.
- [134] Ron Amit, Baruch Epstein, Shay Moran, Ron Meir. Integral Probability Metrics PAC-Bayes Bounds. Technion - Israel Institute of Technology; Google Research, 2022.
- [135] Anna Korba, François Portier. Adaptive Importance Sampling meets Mirror Descent: a Bias-variance tradeoff. CREST, ENSAE, Institut Polytechnique de Paris, ENSAI, 2021.
- [136] Michael J. Lew. A reckless guide to P-values. University of Melbourne, 2019.
- [137] Audun Jsang. Fission of Opinions in Subjective Logic. University of Oslo - UNIK Graduate Center, 2009.
- [138] John Miller, Juan C. Perdomo, Tijana Zrnic. Outside the Echo Chamber: Optimizing the Performative Risk. University of California, Berkeley, 2021.
- [139] Topi Halme, H. Vincent Poor, Visa Koivunen. Sequential Change Detection using Mixtures of Predictive Distributions. Aalto University, Princeton University, 2026.
- [140] Ke-Lin Du, Rengong Zhang, Bingchun Jiang, Jie Zeng, Jiabin Lu. Understanding Machine Learning Principles: Learning, Inference, Generalization, and Computational Learning Theory. Guangdong University of Science and Technology, Zhejiang Yugong Information Technology Co., Ltd., Shenzhen Feng Xing Tai Bao Technology Co., Ltd., Guangdong University of Technology., 2025.

- [141] L. W. Freriks, P. J. M. Cluitmans, M. J. van Gils. The Adaptive Resonance Theory network : (clustering-)behaviour in relation with Brainstem Auditory Evoked Potential patterns. Eindhoven University of Technology (TU/e), 1992.
- [142] J. M. Carlson, John Doyle. Highly Optimized Tolerance: A Mechanism for Power Laws in Designed Systems. University of California, Santa Barbara; California Institute of Technology (Caltech), 1999.
- [143] Nassim Nicholas Taleb. How Much Data Do You Need? A Pre-asymptotic Metric for Fat-tailedness. Tandon School of Engineering, New York University, 2018.
- [144] Omar Rivasplata, Emilio Parrado-Hernández, John Shawe-Taylor, Shiliang Sun, Csaba Szepesvári. PAC-Bayes bounds for stable algorithms with instance-dependent priors. UCL, University Carlos III of Madrid, East China Normal University, DeepMind, 2018.
- [145] Sham M. Kakade, Karthik Sridharan, Ambuj Tewari. On the Complexity of Linear Prediction: Risk Bounds, Margin Bounds, and Regularization. Toyota Technological Institute — Chicago, 2008.
- [146] I. Gibbs and E. Candès. Adaptive conformal inference under distribution shift. *Advances in Neural Information Processing Systems*, 34:1660–1672, 2021, 2021. <https://arxiv.org/abs/2106.00170>
- [147] R. C. Bradley. Basic properties of strong mixing conditions. A survey and some open questions. *Probability Surveys*, 2:107–144, 2005, 2005. <https://doi.org/10.1214/154957805100000104>
- [148] L. Paninski. Estimation of entropy and mutual information. *Neural Computation*, 15(6):1191–1253, 2003, 2003. <https://doi.org/10.1162/089976603321780272>
- [149] R. J. McCann. Existence and uniqueness of monotone measure-preserving maps. *Duke Mathematical Journal*, 80(2):307–324, 1995, 1995. <https://doi.org/10.1215/S0012-7094-95-08013-2>
- [150] R. Dahlhaus. Fitting time series models to nonstationary processes. *The Annals of Statistics*, 25(1):1–37, 1997, 1997. <https://doi.org/10.1214/aos/1034276620>
- [151] L. Ambrosio, N. Gigli, and G. Savaré. *Gradient Flows: in Metric Spaces and in the Space of Probability Measures*. Birkhäuser, 2008, 2008. <https://doi.org/10.1007/978-3-7643-8722-8>
- [152] I. Csiszár. I-divergence geometry of probability distributions and minimization problems. *The Annals of Probability*, 3(1):146–158, 1975, 1975. <https://doi.org/10.1214/aop/1176996454>
- [153] A. Bifet and R. Gavaldà. Learning from time-changing data with adaptive windowing. In *SIAM International Conference on Data Mining*, pages 443–448, 2007, 2007. <https://doi.org/10.1137/1.9781611972771.42>
- [154] J. Gama, P. Medas, G. Castillo, and P. Rodrigues. Learning with drift detection. In *Brazilian Symposium on Artificial Intelligence*, pages 286–295, 2004, 2004. https://doi.org/10.1007/978-3-540-28645-5_29

- [155] E. Hazan, A. Agarwal, and S. Kale. Logarithmic regret algorithms for online convex optimization. *Machine Learning*, 69:169–192, 2007, 2007. <https://doi.org/10.1007/s10994-007-5016-8>
- [156] D. S. Modha and E. Masry. Minimum complexity regression estimation with weakly dependent observations. *IEEE Transactions on Information Theory*, 42(6):2133–2145, 1996, 1996. <https://doi.org/10.1109/18.556602>
- [157] C. Villani. *Optimal Transport: Old and New*. Springer Science & Business Media, volume 338, 2009, 2009. <https://doi.org/10.1007/978-3-540-71050-9>
- [158] B. Yu. Rates of convergence for empirical processes of stationary mixing sequences. *The Annals of Probability*, 22(1):94–116, 1994, 1994. <https://doi.org/10.1214/aop/1176988849>
- [159] Q. Liu and D. Wang. Stein variational gradient descent: A general purpose Bayesian inference algorithm. In *Advances in Neural Information Processing Systems*, volume 29, pages 2378–2386, 2016, 2016. <https://arxiv.org/abs/1608.04471>
- [160] R. Jordan, D. Kinderlehrer, and F. Otto. The variational formulation of the Fokker–Planck equation. *SIAM Journal on Mathematical Analysis*, 29(1):1–17, 1998, 1998. <https://doi.org/10.1137/S0036141096303359>
- [161] J. Dambre, D. Verstraeten, B. Schrauwen, S. Massar. Information processing capacity of dynamical systems. *Scientific Reports*, 2:514, 2012, 2012. <https://doi.org/10.1038/srep00514>
- [162] R. Landauer. Irreversibility and heat generation in the computing process. *IBM Journal of Research and Development*, 5(3):183–191, 1961, 1961. <https://doi.org/10.1147/rd.53.0183>
- [163] C. Godreche, J.-M. Luck. Characterising the nonequilibrium stationary states of Ornstein-Uhlenbeck processes. *Journal of Physics A: Mathematical and Theoretical*, 52(3):035002, 2018, 2018. <https://arxiv.org/abs/1807.00694>
- [164] I. Prigogine. *Time, Structure and Fluctuations*. Nobel Lecture, Premio Nobel de Quimica, 1977. <https://www.nobelprize.org/prizes/chemistry/1977/prigogine/lecture/>
- [165] T. M. Cover, J. A. Thomas. *Elements of Information Theory*. Wiley-Interscience, 2a edicao, 2006. <https://doi.org/10.1002/047174882X>
- [166] V. I. Oseledets. A multiplicative ergodic theorem: Lyapunov characteristic numbers for dynamical systems. *Transactions of the Moscow Mathematical Society*, 19:197–231, 1968, 1968. <https://doi.org/10.1090/trans2/019>
- [167] G. Benettin, L. Galgani, A. Giorgilli, J.-M. Strelcyn. Lyapunov characteristic exponents for smooth dynamical systems and for Hamiltonian systems - a method for computing all of them. *Meccanica*, 15(1):9–20, 1980, 1980. <https://doi.org/10.1007/BF02128236>
- [168] L. N. Trefethen, M. Embree. *Spectra and Pseudospectra: The Behavior of Nonnormal Matrices and Operators*. Princeton University Press, 2005, 2005. <https://doi.org/10.1515/9781400830473>

- [169] R. A. Horn, C. R. Johnson. Matrix Analysis. Cambridge University Press, 2a edicao, 2013, 2013. <https://doi.org/10.1017/CB09781139020411>
- [170] J. D. Lee, I. Panageas, G. Piliouras, M. Simchowitz, M. I. Jordan, B. Recht. First-order methods almost always avoid strict saddle points. Mathematical Programming, 176(1-2):311–337, 2019, 2019. <https://doi.org/10.1007/s10107-019-01374-3>
- [171] N. J. Higham. Accuracy and Stability of Numerical Algorithms. SIAM, 2a edicao, 2002, 2002. <https://doi.org/10.1137/1.9780898718027>
- [172] G. Gallavotti, E. G. D. Cohen. Dynamical ensembles in stationary states. Journal of Statistical Physics, 80(5-6):931–970, 1995, 1995. <https://doi.org/10.1007/BF02179860>
- [173] S. Ghosh. Non-normal spectral signatures of instability in neural network training dynamics. arXiv:2605.23476, 2026. <https://arxiv.org/abs/2605.23476>
- [174] A. H. Ariq. Pseudospectral Bounds for Transient Amplification in Coupled Gradient Descent. arXiv:2606.04031, 2026. <https://arxiv.org/abs/2606.04031>
- [175] R. J. Leveque, L. N. Trefethen. On the resolvent condition in the Kreiss Matrix Theorem. BIT Numerical Mathematics, 24(5):584–591, 1984, 1984. <https://doi.org/10.1007/BF01934916>
- [176] F. L. Bauer, C. T. Fike. Norms and exclusion theorems. Numerische Mathematik, 2(1):137–141, 1960, 1960. <https://doi.org/10.1007/BF01386217>
- [177] P. Henrici. Bounds for iterates, inverses, spectral variation and fields of values of non-normal matrices. Numerische Mathematik, 4(1):24–40, 1962, 1962. <https://doi.org/10.1007/BF01386294>
- [178] L. N. Trefethen, A. E. Trefethen, S. C. Reddy, T. A. Driscoll. Hydrodynamic stability without eigenvalues. Science, 261(5121):578–584, 1993, 1993. <https://doi.org/10.1126/science.261.5121.578>
- [179] B. T. Polyak. Some methods of speeding up the convergence of iteration methods. USSR Computational Mathematics and Mathematical Physics, 4(5):1–17, 1964, 1964. [https://doi.org/10.1016/0041-5553\(64\)90137-5](https://doi.org/10.1016/0041-5553(64)90137-5)
- [180] G. H. Golub, C. F. Van Loan. Matrix Computations. Johns Hopkins University Press, 4a edicao, 2013, 2013. <https://doi.org/10.56021/9781421407944>
- [181] N. J. Higham. Functions of Matrices: Theory and Computation. SIAM, Philadelphia, 2008, 2008. <https://doi.org/10.1137/1.9780898717778>
- [182] I. C. F. Ipsen. Computing an eigenvector with inverse iteration. SIAM Review, 39(2):254–291, 1997, 1997. <https://doi.org/10.1137/S0036144596300773>
- [183] I. Goldhirsch, P.-L. Sulem, S. A. Orszag. Stability and Lyapunov stability of dynamical systems: a differential approach and a numerical method. Physica D: Nonlinear Phenomena, 27(3):311–337, 1987, 1987. [https://doi.org/10.1016/0167-2789\(87\)90034-0](https://doi.org/10.1016/0167-2789(87)90034-0)
- [184] A. Pikovsky, A. Politi. Lyapunov Exponents: A Tool to Explore Complex Dynamics. Cambridge University Press, 2016, 2016. <https://doi.org/10.1017/CB09781139343473>

- [185] W. D. Heiss. The physics of exceptional points. *Journal of Physics A: Mathematical and Theoretical*, 45(44):444016, 2012, 2012. <https://doi.org/10.1088/1751-8113/45/44/444016>
- [186] T. Kato. *Perturbation Theory for Linear Operators*. Springer, Classics in Mathematics, 1995, 1995. <https://doi.org/10.1007/978-3-642-66282-9>
- [187] M. V. Berry. Physics of nonhermitian degeneracies. *Czechoslovak Journal of Physics*, 54(10):1039–1047, 2004, 2004. <https://doi.org/10.1023/B:CJOP.0000044002.05657.04>
- [188] L. N. Trefethen. Pseudospectra of linear operators. *SIAM Review*, 39(3):383–406, 1997, 1997. <https://doi.org/10.1137/S0036144595295284>
- [189] Y. Bengio, N. Leonard, A. Courville. Estimating or Propagating Gradients Through Stochastic Neurons for Conditional Computation. *arXiv:1308.3432*, 2013. <https://arxiv.org/abs/1308.3432>
- [190] G. Kerg, K. Goyette, M. Puelma Touzel, G. Gidel, E. Vorontsov, Y. Bengio, G. Lajoie. Non-normal Recurrent Neural Network (nnRNN): learning long time dependencies while improving expressivity with transient dynamics. *NeurIPS 2019*; *arXiv:1905.12080*, 2019. <https://arxiv.org/abs/1905.12080>
- [191] J. D. Botha. Products of diagonalizable matrices. *Linear Algebra and its Applications*, 273:65–82, 1998. [https://doi.org/10.1016/S0024-3795\(97\)00344-3](https://doi.org/10.1016/S0024-3795(97)00344-3)
- [192] H. Flanders. Elementary divisors of AB and BA . *Proceedings of the American Mathematical Society*, 2:871–874, 1951. <https://doi.org/10.1090/S0002-9939-1951-0044493-X>
- [193] R. A. Lippert, G. Strang. The Jordan forms of AB and BA . *Electronic Journal of Linear Algebra*, 18, 2009. <https://doi.org/10.13001/1081-3810.1313>
- [194] A. Eskin, C. Matheus. Semisimplicity of the Lyapunov spectrum for irreducible cocycles. *Israel Journal of Mathematics*, 230:973–1005, 2019. <https://doi.org/10.1007/s11856-019-1841-2>
- [195] J. Bochi, P. Lessa. On the distribution of the angle between Oseledets spaces. *Annales Henri Lebesgue*, 9:65–84, 2026. <https://doi.org/10.5802/ahl.260>
- [196] W. M. Goldman. An exposition of results of Fricke. *arXiv:math/0402103*, 2004. <https://arxiv.org/abs/math/0402103>
- [197] R. Fricke. *Vorlesungen über die Theorie der automorphen Functionen*, Band 1. B. G. Teubner, Leipzig, 1897. <https://archive.org/details/vorlesungenber01fricuoft>
- [198] A. F. Beardon. *The Geometry of Discrete Groups*. Graduate Texts in Mathematics 91, Springer, 1983. <https://doi.org/10.1007/978-1-4612-1146-4>
- [199] Niklas Pfister, Peter Bühlmann, Bernhard Schölkopf, Jonas Peters. Kernel-Based Tests for Joint Independence. *Journal of the Royal Statistical Society Series B*, 80(1):5–31, 2018. <https://doi.org/10.1111/rssb.12235>

- [200] Gábor J. Székely, Maria L. Rizzo, Nail K. Bakirov. Measuring and testing dependence by correlation of distances. *The Annals of Statistics*, 35(6):2769-2794, 2007. <https://doi.org/10.1214/009053607000000505>
- [201] Abraham Wald. Sequential Tests of Statistical Hypotheses. *The Annals of Mathematical Statistics*, 16(2):117-186, 1945. <https://doi.org/10.1214/aoms/1177731118>
- [202] Robert E. Kass, Adrian E. Raftery. Bayes Factors. *Journal of the American Statistical Association*, 90(430):773-795, 1995. <https://doi.org/10.1080/01621459.1995.10476572>
- [203] Vladimir N. Vapnik, Alexey Ya. Chervonenkis. On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities. *Theory of Probability & Its Applications*, 16(2):264-280, 1971. <https://doi.org/10.1137/1116025>
- [204] Bradley Efron. Bootstrap Methods: Another Look at the Jackknife. *The Annals of Statistics*, 7(1):1-26, 1979. <https://doi.org/10.1214/aos/1176344552>
- [205] John P. A. Ioannidis. Why Most Published Research Findings Are False. *PLoS Medicine*, 2(8):e124, 2005. <https://doi.org/10.1371/journal.pmed.0020124>
- [206] Ronald L. Wasserstein, Nicole A. Lazar. The ASA Statement on p-Values: Context, Process, and Purpose. *The American Statistician*, 70(2):129-133, 2016. <https://doi.org/10.1080/00031305.2016.1154108>
- [207] Brandon Amos, Lei Xu, J. Zico Kolter. Input Convex Neural Networks. *Proceedings of the 34th International Conference on Machine Learning (PMLR 70:316-325)*, 2017. <https://proceedings.mlr.press/v70/amos17a.html>
- [208] Wolfgang Maass, Thomas Natschläger, Henry Markram. Real-Time Computing Without Stable States: A New Framework for Neural Computation Based on Perturbations. *Neural Computation*, 14(11):2531-2560, 2002. <https://doi.org/10.1162/089976602760407955>
- [209] Arthur P. Dempster. Upper and Lower Probabilities Induced by a Multivalued Mapping. *The Annals of Mathematical Statistics*, 38(2):325-339, 1967. <https://doi.org/10.1214/aoms/1177698950>
- [210] Audun Jsang. *Subjective Logic: A Formalism for Reasoning Under Uncertainty*. Springer (Artificial Intelligence: Foundations, Theory, and Algorithms), 2016. <https://doi.org/10.1007/978-3-319-42337-1>
- [211] Noga Alon, Yossi Matias, Mario Szegedy. The Space Complexity of Approximating the Frequency Moments. *Journal of Computer and System Sciences*, 58(1):137-147, 1999. <https://doi.org/10.1006/jcss.1997.1545>
- [212] Piotr Indyk, David P. Woodruff. Optimal Approximations of the Frequency Moments of Data Streams. *Proceedings of the 37th Annual ACM Symposium on Theory of Computing (STOC)*, 202-208, 2005. <https://doi.org/10.1145/1060590.1060621>
- [213] David P. Woodruff. Sketching as a Tool for Numerical Linear Algebra. *Foundations and Trends in Theoretical Computer Science*, 10(1-2):1-157, 2014. <https://doi.org/10.1561/04000000060>

- [214] Celestine Mender-Dünner, Juan Perdomo, Tijana Zrnic, Moritz Hardt. Stochastic Optimization for Performative Prediction. Proceedings of the 37th International Conference on Machine Learning (PMLR 119:7081-7090), 2020. <https://proceedings.mlr.press/v119/mender-dunner20a.html>
- [215] T. Higuchi. Approach to an Irregular Time Series on the Basis of the Fractal Theory. *Physica D: Nonlinear Phenomena*, 31(2):277-283, 1988. [https://doi.org/10.1016/0167-2789\(88\)90081-4](https://doi.org/10.1016/0167-2789(88)90081-4)
- [216] Israel Gohberg, Peter Lancaster, Leiba Rodman. Invariant Subspaces of Matrices with Applications. Society for Industrial and Applied Mathematics (SIAM Classics in Applied Mathematics 51), 2006. <https://doi.org/10.1137/1.9780898719093>
- [217] Philippe Bougerol, Jean Lacroix. Products of Random Matrices with Applications to Schrödinger Operators. Birkhäuser Boston (Progress in Probability and Statistics 8), 1985. <https://doi.org/10.1007/978-1-4684-9172-2>
- [218] Per Bak, Chao Tang, Kurt Wiesenfeld. Self-organized Criticality: An Explanation of $1/f$ Noise. *Physical Review Letters*, 59(4):381-384, 1987. <https://doi.org/10.1103/PhysRevLett.59.381>
- [219] Sergey V. Buldyrev, Roni Parshani, Gerald Paul, H. Eugene Stanley, Shlomo Havlin. Catastrophic Cascade of Failures in Interdependent Networks. *Nature*, 464:1025-1028, 2010. <https://doi.org/10.1038/nature08932>
- [220] Marten Scheffer, Jordi Bascompte, William A. Brock, Victor Brovkin, Stephen R. Carpenter, Vasilis Dakos, Hermann Held, Egbert H. van Nes, Max Rietkerk, George Sugihara. Early-warning signals for critical transitions. *Nature*, 461:53-59, 2009. <https://doi.org/10.1038/nature08227>
- [221] Vasilis Dakos, Stephen R. Carpenter, William A. Brock, Aaron M. Ellison, Vishwesha Guttal, Anthony R. Ives, Sonia Kéfi, David A. Seekell, and others. Methods for Detecting Early Warnings of Critical Transitions in Time Series Illustrated Using Simulated Ecological Data. *PLoS ONE*, 7(7):e41010, 2012. <https://doi.org/10.1371/journal.pone.0041010>
- [222] Vivek S. Borkar. Stochastic approximation with two time scales. *Systems & Control Letters*, 29(5):291-294, 1997. [https://doi.org/10.1016/S0167-6911\(97\)00015-1](https://doi.org/10.1016/S0167-6911(97)00015-1)
- [223] Richard S. Sutton, Doina Precup, Satinder Singh. Between MDPs and semi-MDPs: A framework for temporal abstraction in reinforcement learning. *Artificial Intelligence*, 112(1-2):181-211, 1999. [https://doi.org/10.1016/S0004-3702\(99\)00052-1](https://doi.org/10.1016/S0004-3702(99)00052-1)
- [224] Andrew Y. Ng, Daishi Harada, Stuart Russell. Policy invariance under reward transformations: Theory and application to reward shaping. Proceedings of the 16th International Conference on Machine Learning, 278-287, 1999. <https://people.eecs.berkeley.edu/~russell/papers/ml99-shaping.pdf>
- [225] Herbert Jaeger. The echo state approach to analysing and training recurrent neural networks. GMD Report 148, German National Research Center for Information Technology, 2001. <https://www.ai.rug.nl/minds/uploads/EchoStatesTechRep.pdf>

- [226] Allen G. Hart, James L. Hook, Jonathan H. P. Dawes. Embedding and approximation theorems for echo state networks. *Neural Networks*, 128:234-247, 2020. <https://doi.org/10.1016/j.neunet.2020.05.006>
- [227] M. U. Gaimann et al.. Optimal information injection and transfer mechanisms for active matter reservoir computing. *arXiv:2509.01799*, 2025. <https://arxiv.org/abs/2509.01799>
- [228] Édgar Roldán, Izaak Neri, Meinolf Roldán, Jürgen Mehl, Frank Jülicher. Statistics of Infima and Stopping Times of Entropy Production and Applications to Active Molecular Processes. *Physical Review X*, 7(2):021026, 2017. <https://doi.org/10.1103/PhysRevX.7.021026>
- [229] Yoshihiko Hasegawa. Uncertainty relations in stochastic processes: An information inequality approach. *Physical Review E*, 99(6):062126, 2019. <https://doi.org/10.1103/PhysRevE.99.062126>
- [230] Jean-David Benamou, Yann Brenier. A computational fluid mechanics solution to the Monge-Kantorovich mass transfer problem. *Numerische Mathematik*, 84(3):375-393, 2000. <https://doi.org/10.1007/s002110050002>
- [231] Gunnar Blom. Some properties of incomplete U-statistics. *Biometrika*, 63(3):573-580, 1976. <https://doi.org/10.1093/biomet/63.3.573>
- [232] Xiaoming Huo, Gábor J. Székely. Fast Computing for Distance Covariance. *Technometrics*, 58(4):435-447, 2016. <https://doi.org/10.1080/00401706.2015.1054435>
- [233] I. Richard Savage. Mills' ratio for multivariate normal distributions. *Journal of Research of the National Bureau of Standards B*, 66(3):93-96, 1962. https://nvlpubs.nist.gov/nistpubs/jres/66B/jresv66n3p93_A1b.pdf
- [234] Enkelejd Hashorva, Jürg Hüsler. On multivariate Gaussian tails. *Annals of the Institute of Statistical Mathematics*, 55(3):507-522, 2003. <https://doi.org/10.1007/BF02530509>